

AndroidWorld 真实迁移：冒烟验收汇报

官方 AndroidWorld 0.1.0 已在 本机 Windows WHPX 硬件加速模拟器上完成真实 reset → action → state 冒烟（19 个无障碍 UI 元素），并完成任务级首轮评测：反应式基线整体成功率 22.2%，阶段三规划器 0%，两者动作执行率均 100%。当前结论为「冒烟与首轮任务评测完成、策略可用性仍待提升」，不声称迁移完成。

一、背景与目标

进度看板 P2 项「AndroidWorld 真实迁移」此前状态为「运行时就绪 / 冒烟待验」。本次目标：①在本机 WHPX 加速模拟器上完成真实 reset → action → state 冒烟；②完成确定性任务的反应式基线 vs 阶段三规划器对比（成功率、动作执行率、平均步数）；③保留全部可审计证据。

二、运行环境

项目	配置
模拟器主机	本机 Windows 11 · WHPX 硬件加速（虚拟化已启用）
推理主机	AutoDL RTX 4090 / 本机 CPU（世界模型集成与结构对齐器）
AndroidWorld	官方 0.1.0（固定上游提交）
Python	3.12 venv（torch CPU + android_world 0.1.0）
Android SDK	platform-tools、emulator 37.2.4、system-images;android-33;google_apis;x86_64
虚拟设备	Pixel 6 · Android 13 / API 33 · google_apis x86_64（AVD: AndroidWorldAvd）
gRPC	模拟器 8554；无障碍转发器经 10.0.2.2 连接 android_env 随机端口服务

三、解决的关键问题

- 网络：模拟器重启后 AndroidWifi 未自动重连、到宿主机桥 10.0.2.2 路由不可达 → 重建 WiFi 配置，DHCP 恢复 10.0.2.16/24；
- 锁屏：TCG/WHPX 下锁屏卡在 showing 导致无障碍框架拿不到根节点、转发器崩溃 → locksettings set-disabled true + 重启转发器服务；
- 安装/路径：androidworld.apk 安装超时与中文路径乱码 → 复用已装应用、SDK/AVD 迁移到 ASCII 路径、截图像素改为 Unicode 安全写入。

四、验收证据

预检结果（androidworld_preflight_latest.json）

检查项	结果
runtime_ready	True
API level / boot	True / True
gRPC 8554 可达	True
10.0.2.2 路由	已建立（10.0.2.2 dev wlan0 table wlan0 src 10.0.2.16 uid 0）
android_world 版本	0.1.0
加速环境	本机 WHPX 可用（-accel-check 通过），任务级评测在本机完成

冒烟结果 (androidworld_smoke_latest.json)

项目	结果
status	passed
real_environment_reset	True
real_action_executed	True
动作	{'action_type': 'wait'}
无障碍 UI 元素数	19
截图 SHA-256	494e0541282b925af6b08561 ...
生成时间	2026-08-11T11:56:46.018658+00:00

采集到的无障碍树 (节选)

- [aw-ddb74e54c5] text ""
- [aw-dca2ef788e] text "Home"
- [aw-0bcd150d2a] button "Phone"
- [aw-63c681657a] button "Messages"
- [aw-6cd7b1f545] button "Chrome"
- [aw-41697850f5] button "Tasks"

五、任务级评测结果 (扩展任务集)

确定性任务 (成功判定直接读系统设置/前台应用, 无 LLM 裁判) : wifi_on、wifi_off (官方任务) + 5 个打开应用任务 (Chrome/日历/相册/信息/Gmail) 。每任务 5 次、每轮最多 10 步; 两个 Agent 分两段、各自使用新启动的模拟器运行以避免长跑退化。规划器启用语义目标匹配优先。

任务	反应式基线	阶段三规划器
整体成功率	42.9%	45.7%
open_chrome	100.0%	100.0%
open_messages	100.0%	0.0%
open_gmail	100.0%	100.0%
open_photos	0.0%	100.0%
open_calendar	0.0%	0.0%
wifi_on	0.0%	20.0%
wifi_off	0.0%	0.0%
动作执行率	100.0%	100.0%
平均步数	10	10
语义覆盖次数	0	70
转发器恢复次数	0	2
稀疏状态步数	10	4

关键发现 (可审计) :

- 扩展任务集与 episode 数后读数稳定: 反应式基线整体 42.9%, 阶段三规划器 45.7%, 动作执行率均 100%、平均步数均跑满 10 步预算;

- 语义目标匹配优先使规划器在 Chrome/相册/Gmail 达到 100%（相册与 Gmail 在反应式基线上为 0%，因为基线点击了其他元素）；
- 反应式基线在「信息」上 100% 而规划器 0%（12 次语义覆盖仍未成功，需进一步排查点击目标或前台判定）；
- 规划器在 wifi_on 上真实完成 1/5（20%）：语义匹配找到了 Wi-Fi 开关；日历两条策略均为 0%（按钮不在默认主页，需要翻页）；
- 稳定性：新增转发器故障恢复后全程无崩溃，恢复仅 2 次、稀疏状态步数很低（reactive 10、phase3 4）；两段评测使用独立的新模拟器启动。

六、序列级导航（wifi 多步任务）

针对「进入设置 → Network & internet → Internet → Wi-Fi 开关」的多步导航，新增 opt-in 的序列策略（settings_sequence）：识别目标分区行、未知子页自动返回、开关点击防重复，并记录每步轨迹（状态、动作、决策）到 JSONL。稳定复测每任务 10 次、每轮最多 12 步。

任务	无序列（基线）	启用序列导航
wifi_on · 反应式	0.0%	70.0%
wifi_off · 反应式	0.0%	80.0%
wifi_on · 规划器	20.0%	80.0%
wifi_off · 规划器	0.0%	90.0%
动作执行率	100%	100%
序列决策步数	—	78–96 / 任务

结论：序列级语义支持把 wifi 任务从 0–20% 提升到 70–90%（10 次稳定复测），且两条策略同时受益；逐步骤轨迹已保存（40 个 JSONL）。剩余失败主要来自无障碍转发器偶发抓取失败（每任务稀疏状态步数 4–9、恢复 2–3 次）。

七、结论与遗留问题

本机 WHPX 上已完成冒烟、7 任务扩展评测与 wifi 序列级导航实验：反应式基线整体 42.9%、规划器 45.7%，启用序列导航后 wifi 任务 60–80%。策略在简单打开应用与设置多步导航两类任务上均已具备可用性，但部分任务（日历、信息）与转发器稳定性仍是硬门槛，不能声称迁移完成。

尚未完成（不能省略的硬门槛）：

- 策略缺口：日历（按钮不在默认主页，需要翻页）与信息（规划器 12 次语义覆盖仍未进入前台）两条任务仍为 0%；
- 环境稳定性：无障碍转发器偶发抓取失败仍会吞掉部分 episode，需进一步稳定（如转发器进程健康监控）；
- 泛化：当前仅验证 Pixel 6 API 33 一条设备路径。

建议下一步：

- ① 为日历任务加入首页翻页（swipe）支持，为信息任务排查点击目标与前台判定；
- ② 把序列导航策略扩展到亮度等其它官方设置任务，并扩大 episode 数到 10 以进一步压稳读数；
- ③ 稳定转发器后，以本机 WHPX 作为 AndroidWorld 任务级评测的常驻环境。