

阶段二、阶段三多次训练 完善与复核报告

动作条件世界模型 · 五次独立训练 · 三模型校准集成 · 动态结构对齐 · 有限步候选决策

训练次数 5 次 种子 17/29/42/73/101	数据规模 3,333 条 1,550 episodes	风险 ECE 0.0104 原单模型 0.0266	结构 Top-1 82.9% 规则基线 63.9%
--	--	--	--

结论：阶段二测试门槛 12/12 通过，阶段三工程门槛 6/6 通过。校准、回归和结构对齐明显改善；观察反事实集成排序与真实 WebArena 成功率未改善，均作为遗留问题保留。

生成时间：2026-08-08 23:52 (Asia/Shanghai)

一、阶段二：五次独立训练与校准集成

数据集共 3,333 条转移、1,550 个 episode、30 个任务，按 episode 切分为训练/验证/测试 2,342/476/515，无跨 split 泄漏。仅使用验证集选择前三个成员。

变体	种子	最佳 epoch	验证选择分	测试风险 F1
risk_balanced_b	101	28	0.8118	0.9273
base_a	17	36	0.8058	0.8774
base_b	42	35	0.8058	0.9074
risk_balanced_a	29	35	0.8022	0.8824
regularized	73	40	0.7990	0.8939

集成测试指标

指标	原单模型	新集成	结论
风险 ECE	0.0266	0.0104	改善 60.9%
进度 MAE	0.0612	0.0543	改善 11.3%
奖励 MAE	0.0620	0.0564	改善 9.0%
状态变化 F1	0.9887	0.9914	提升
风险 AUROC	0.9936	0.9942	提升
风险 F1	0.9074	0.9049	略降

最佳单模型种子 101 的测试风险 F1 为 0.9273；因此保留它作为分类 champion，三模型集成主要用于概率校准、不确定性估计和安全门控。

二、阶段三：结构对齐与有限步前瞻

动态结构对齐器测试 Top-1 从 63.9% 提升到 82.9%，MRR 从 0.8156 提升到 0.9054，Recall@3 保持 100%。

阶梯	总体动作一致率	成功动作一致率	危险动作规避率
reactive	64.1%	74.0%	45.8%
w0_one_step	34.2%	68.8%	65.8%
w1_structure	34.0%	68.8%	65.5%
w2_multiscale	21.2%	58.4%	88.7%
phase3	35.7%	64.9%	66.5%

H=1/2/3 消融

视野	动作一致率	平均延迟
H=1	35.3%	5.32 ms
H=2	23.9%	13.58 ms
H=3	21.2%	34.45 ms

515/515 条测试状态成功匹配，候选合法率 100.0%，安全动作 Recall@k=100.0%，解释完整率 100.0%。W3 平均置信度 0.690，推理平均/P95=20.59/64.03 ms。

消融结论：H=2/3 在当前数据上累积模型偏差并降低动作一致率，因此 W3 使用置信度自适应视野，不把更深想象默认为更优。

三、反事实、在线评测与诚实边界

观察反事实排序

方法	验证配对准确率	测试配对准确率	测试 NDCG@2	测试 RankFlip
最佳单模型	90.0%	61.5%	0.8580	38.5%
校准集成	90.0%	53.8%	0.8297	46.2%

验证集两种方法同为 90%，测试有效配对很少，集成反而更差。报告保留该负结果，未使用测试集调权。

真实 WebArena Reddit 在线贯通

指标	结果
固定任务	27 - 31，共 5 个
执行动作	30 步
动作执行率	100.0%
自主成功率	0.0%
运行失败	0

在线链路已经把本机 BrowserGym/WebArena、SSH 转发和 GPU 三模型集成真正连通；但规则候选尚不能完成可靠的信息检索、答案生成和终止。完整多站点 WebArena 与相对 SR +10% 属于阶段四。

四、交付物、复现入口与遗留问题

交付物	位置
五个世界模型	artifacts/phase2/multiseed/
三模型集成清单	artifacts/phase2/world_model_ensemble_p1.json
结构对齐模型	artifacts/phase3/structure_aligner_best.pt
阶段二集成测试	data/reports/phase2_ensemble_evaluation_test_gpu.json
阶段三完整评测	data/reports/phase3_evaluation_ensemble_gpu.json
在线 WebArena 报告	data/reports/webarena_phase3_online_evaluation_gpu.json
结果看板	output/phase23_dashboard.html 与 site/
GPU 服务器	/root/autodl-tmp/agent_world_model_phase2

复现入口

环节	命令
五次训练	<code>python scripts/train_phase2_multiseed.py --config configs/phase2_world_model_multiseed.json --device cuda</code>
结构训练	<code>python scripts/train_structure_alignment.py --config configs/phase3_structure_alignment.json --device cuda</code>
反事实	<code>python scripts/evaluate_counterfactual_ranking.py --dataset-dir data/phase2_p1 --device cuda</code>
阶段三	<code>python scripts/evaluate_phase3_planner.py --config configs/phase3_planner.json --dataset-dir data/phase2_p1 --device cuda</code>

尚未解决

优先级	问题	下一步
P0	真实 WebArena SR 仍为 0%	补语义检索/作答/终止策略，扩展完整站点
P0	观察反事实仅 100 对，集成排序变差	扩充同状态受控替代动作
P1	H=2/3 累积偏差	增加多步真实轨迹和失败标签
P1	启发式标签占比高	人工核验并加入 WebArena 真实结果
P2	AndroidWorld 无真实运行环境	准备 ADB、模拟器和运行包
外部	GitHub 无账号/remote; Sites 未返回项目 ID	连接账户后继续发布

报告完