

WebArena 未见任务 2×2 在线因果实验报告

Reactive / W4 × 导航护栏开 / 关
3 站 × 30 题 × 4 单元 = 360 episodes

验收结论：P0 的冻结 holdout、等预算 2×2 在线运行、配对分析和 360 条轨迹归档均已完成；但是四个单元的成功率均为 0/90。W4 相对 Reactive 的绝对提升为 0.00 个百分点，基线为 0 使相对提升不可定义，因此相对 SR +10% 性能目标未达成。

P0 子任务	完成状态	性能判定
未见 WebArena holdout	完成：3 站、每站 30 题	在线能力未达标
隔离世界模型因果贡献	完成：2×2 + 配对 CI	未观察到贡献
冲刺相对 SR +10%	实验完成	目标未达成

报告生成：2026-08-14 00:37 (Asia/Shanghai)

一、实验设计与冻结完整性

核心边界：这是修复前冻结、未使用任务反馈的 90 题三站 holdout；它比早期 9 题 post-fix 回归更能衡量未见任务表现，但仍不是完整 812 题 WebArena benchmark。

设计项	冻结值	验收意义
站点与任务	GitLab / Reddit / Shopping; 30 题/站	覆盖三类真实在线站点
实验单元	Reactive/W4 × 护栏关/开	拆分世界模型与共享护栏效应
预算	seed 0; 每题最多 12 步	四单元严格同预算配对
总规模	90 个唯一任务; 360 episodes	满足 P0 最低验收设计
冻结时点	2026-08-13T08:47:08.537751+00:00	首次 holdout episode 前冻结
反馈规则	task_feedback_used=false	无问题修复、替换或调参

不可变性证明

- 任务冻结 SHA-256: cfd7547da262a9a678f43925c301e5acb3cd54efffa753a0bdd46e290288d9fb。
- Agent 发布指纹: 427049583ec231a5f6c49450cd2da51da36ea255ae42ccb1770a9a027b956652。
- W4 四单元均核对远程健康证明; 护栏标签与单元一致, semantic goal override=false。
- 冻结后未更改任务、模型权重、规则护栏、评测器或步数预算; 中断/重叠运行被移出正式证据。

外部模糊判分器的确定性处理

- 官方 fuzzy-match evaluator 需要外部 API 密钥; 本次共有 28 个“任务×单元”缺少该密钥。
- 原始运行在 reset 阶段被密钥检查阻断; 随后使用最小恢复适配器重新真实执行: 只把“尚未提交答案”的校验短路为非终止 0 分, 若提交答案则仍委托原官方 evaluator。
- 28 条恢复轨迹均非空、完成真实决策且没有 send_msg; 因此不读取参考答案、不模拟 LLM judge, 按确定性失败计 0。原始异常、恢复规则与轨迹哈希全部保留。
- 分析结束后 unresolved evaluator failures=0, 90 个任务在四单元中均有一致判定。

二、四单元在线关键数据

单元	成功	SR (95% Wilson CI)	动作执行率	平均步数	平均延迟
Reactive / 护栏关	0/90	0.0% (0.0%-4.1%)	94.3%	11.99	85.12 s
Reactive / 护栏开	0/90	0.0% (0.0%-4.1%)	89.2%	11.32	82.52 s
W4 / 护栏关	0/90	0.0% (0.0%-4.1%)	93.7%	12.00	86.81 s
W4 / 护栏开	0/90	0.0% (0.0%-4.1%)	93.8%	11.78	85.87 s

性能判读：四单元元点估计均为 0%，单个 90 题单元的 95% Wilson 上界约为 4.1%。结果不是“尚未统计清楚”，而是在本次冻结范围内没有观察到任何成功；同时，0% 基线造成明显地板效应，限制了对较小方法差异的识别。

分站点结果

站点	Reactive/关	W4/关	Reactive/开	W4/开
gitlab	0/30	0/30	0/30	0/30
reddit	0/30	0/30	0/30	0/30
shopping	0/30	0/30	0/30	0/30

与早期三站 9 题回归的关系

- 早期 9 题 post-fix 回归中 Reactive 与 W4 均为 9/9；该结果使用了问题失败反馈修复后的共享导航规则，只证明回归链路。
- 本次 90 题未见集合在冻结后没有使用任务反馈，四单元均为 0/90。二者的巨大落差表明早期 9/9 不能外推为泛化能力。
- 不同任务集合之间不做显著性检验；对比用于解释证据层级，不把差异简单归因为某一个代码改动。

三、配对因果分析

90 个任务按站点、task id 和 seed 一一配对；差值置信区间使用 20,000 次任务级配对 bootstrap。护栏效应只归因于共享导航规则；只有同一护栏水平下的 W4-Reactive 差值用于估计世界模型贡献。

配对对比	基线 SR	候选 SR	绝对差	95% 配对 CI	仅候选成功
W4-Reactive（护栏关）	0.0%	0.0%	+0.00 pp	[+0.00, +0.00] pp	0
W4-Reactive（护栏开）	0.0%	0.0%	+0.00 pp	[+0.00, +0.00] pp	0
护栏开-关（Reactive）	0.0%	0.0%	+0.00 pp	[+0.00, +0.00] pp	0
护栏开-关（W4）	0.0%	0.0%	+0.00 pp	[+0.00, +0.00] pp	0

2×2 主效应与交互

效应	点估计	95% CI
世界模型主效应（跨护栏平均）	+0.00 pp	[+0.00, +0.00] pp
护栏主效应（跨 Agent 平均）	+0.00 pp	[+0.00, +0.00] pp
世界模型×护栏交互	+0.00 pp	[+0.00, +0.00] pp

因果结论：在本次冻结 holdout 与预算下，W4、导航护栏以及两者交互的成功率效应点估计均为 0.00 个百分点。不能声称世界模型带来在线成功率收益；全零结局还意味着该 2×2 设计虽执行完整，却处于地板区，无法回答模型在“已有基础成功能力”条件下是否能改善边缘任务。

四、P0 验收、完成好坏与遗留问题

验收项	设计完成度	结果质量	最终判定
未见 WebArena holdout	90/90 题；360/360 episodes	冻结与证据链完整；SR=0%	实验完成，能力不足
隔离世界模型贡献	2×2、同预算、配对 CI 完成	主效应=0 pp；存在地板效应	因果流程完成，无正向证据
相对 SR +10%	按预注册主对比评估	Reactive=0%，相对值不可定义	性能目标未达成

完成得好的部分

- 修复前冻结 90 题，明确排除全部历史使用任务；不因结果差而替换题目。
- 同一任务四单元配对、步数预算一致，W4 发布指纹与护栏状态可验证。
- 正式与中断/重叠运行隔离；最终分析只白名单引用 360 条轨迹并核验 SHA-256。
- 负结果、相对提升不可定义和外部判分依赖均透明呈现。

完成不足与研究遗留

- Agent 没有在 90 个未见任务中完成任何一个任务；核心在线能力严重不足。
- 规则候选与目标理解不足以覆盖真实任务，世界模型只能重排既有候选，无法补偿候选空间缺失。
- 全零基线导致地板效应；下一轮应先把 Reactive 基线提升到非零，再复用冻结协议评估 W4 增量。
- 当前结论只适用于 Classic WebArena 三站 90 题，不代表完整 812 题，也不覆盖其他站点。

建议下一步

优先级	工作	最低验收	GPU
P0	提升基础策略与候选生成	新的开发集上形成非零 SR；不可触碰本次 holdout	训练/推理需要
P0	重新冻结第二套未见集合	修复完成后再冻结；报告绝对 pp、相对值与配对 CI	推理需要
P1	错误类型诊断	对 360 轨迹统计目标理解、候选缺失、执行失败与循环	不需要
P1	完整 benchmark 扩展	先做分层功效分析，再扩展站点与多种子	推理建议

五、证据索引与可复核性

证据	路径 / 数量
冻结主清单	configs/webarena_p0_holdout_frozen.json
冻结站点配置	configs/webarena_p0_holdout_{gitlab,reddit,shopping}_frozen.json
四单元分析	data/reports/webarena_p0_2x2_analysis.json
原始单元报告	data/reports/webarena_p0___guard_.json （12 份）
恢复单元报告	data/reports/webarena_p0_recovery___guard_.json （12 份）
清洁轨迹归档	data/trajectories_webarena_p0_evidence/ （360 条 + manifest.json）
运行器	scripts/run_webarena_p0_cell.sh （同站互斥锁、冻结校验、服务重建）
恢复适配器	scripts/recover_webarena_p0_fuzzy_episodes.py （只短路无答案校验）
分析器	scripts/analyze_webarena_p0_2x2.py （Wilson CI、配对 bootstrap、2×2 效应）

关键证据摘要

- 分析任务数：90；分析 episodes：360。
- 清洁归档 episodes：360；源分析
SHA-256：f783b0acf4ada6bbaa38da4f01f2b7c2a909ec9e43f55976fb8c58a200c73ab6。
- 冻结清单 SHA-256：cfd7547da262a9a678f43925c301e5acb3cd54efffa753a0bdd46e290288d9fb。
- W4 发布指纹：427049583ec231a5f6c49450cd2da51da36ea255ae42ccb1770a9a027b956652。

最终科研表述：本项目已完成 P0 预定的 90 题三站未见任务和 2×2 因果评估，解决了“没有未见在线集合、无法区分护栏与世界模型”的证据缺口；结果显示四单元均为 0% SR，W4 没有可观察在线增益，申报书相对 SR +10% 指标未达成。P0 应记为“实验与证据交付完成，性能目标失败”。