

阶段二与阶段三最终结论汇报

面向《大创申报书 33.0》的技术路线，汇总阶段二（动作条件世界模型）与阶段三（候选动作生成、1–3 步推演与有限步重排）的最终结论：5 项已完成、2 项部分完成、1 项未执行。所有结论均来自已同步的 JSON 报告与真实运行证据，未把离线指标等同于 WebArena 在线成功率。

一、最终结论总览

最终结论	状态
观察反事实采集	3,600 对有效, 3,050 对有信息
阶段二数据质量门禁	全部通过
RTX 4090 多种子训练	5 次训练, 选择 3 个成员
阶段二独立测试	12 项验收检查全部通过
阶段三反事实与多步评估	两项验收均通过
高风险证据复核	500 条 evidence_verified; 自动证据验收通过
AndroidWorld	真实 reset/action 冒烟通过; 任务级基线/规划器对比仍待 KVM 环境
WebArena 在线重评	本轮未执行, 不能声称成功率提高

二、已完成项 (5 项)

1. 观察反事实采集

3,600 对全部有效、3,050 对有信息（信息率 84.72%）、0 采集失败、配对状态匹配率 100%，且同一初始状态的全部干预只进入一个数据划分，无跨 split 泄漏。

2. 阶段二数据质量门禁

训练数据 13,348 条转移、5,930 个 episode、30 个任务；train/validation/test 划分无重复样本与无 episode 泄漏，P0/P1 数据门槛通过。

3. RTX 4090 多种子训练

完成 5 个随机种子 (17/29/42/73/101) 的独立训练，仅按验证集选择 3 个成员组成集成；风险校准 ECE 由 0.0266 降至 0.0104，进度 MAE 由 0.0612 降至 0.0543。

4. 阶段二独立测试

12 项验收检查全部通过：状态变化 F1 98.69%、任务信号 F1 98.90%、风险 F1 94.39%、风险 AUROC 99.04%、进度 MAE 0.0992。

5. 阶段三反事实与多步评估

两项验收均通过：反事实排序 396 个有效测试配对、Pairwise Accuracy 97.73%、NDCG@2 0.9916、集成遗憾 0.0511；真实连续轨迹 H=1/2/3 窗口分别为 1,943/619/329。

三、部分完成项 (2 项)

6. 高风险证据复核

500/500 条高风险、终止与严重失败样本均唯一回溯到原始环境轨迹，已写为 evidence_verified 并完成自动证据验收；按项目规则人工签字不是验收门槛，审计来源仍如实保留 (human_signoff=false, 不冒充人工审核)。

7. AndroidWorld

官方 0.1.0 在 API 33 软件仿真设备上完成真实 reset/action/state 冒烟（18 个无障碍 UI 元素，截图带 SHA-256 证据）；容器无 /dev/kvm，任务级基线/规划器对比仍需 KVM 加速主机，因此不能声称迁移完成。

四、未完成项（1 项）

8. WebArena 在线重评

本轮未配置多站点在线环境，未执行新的成功率评测，因此不能声称成功率提高。已具备可重复的 Reddit 在线评测链，自主 Agent 此前实测 0/5，相对反应式基线提升 +10% 属于阶段四目标。

五、总体结论与下一步

阶段二与阶段三的离线工程目标已经完成：数据规模与质量门禁通过，五次多种子 GPU 训练完成，阶段二联合预测和阶段三反事实/多步评估均通过既定验收；证据复核与 AndroidWorld 冒烟也已完成。未完成的是 WebArena 在线成功率提升和 AndroidWorld 任务级迁移验收，这些事项不得被当前离线结果替代。

建议按以下顺序推进：

- 1. 恢复 WebArena 多站点在线评测链，以固定任务、固定预算、固定种子做重评，核对相对基线的成功率提升；
- 2. 将 AndroidWorld 模拟器迁移到 KVM 主机（或本机 WHPX），复跑预检与冒烟后执行任务级基线/规划器对比；
- 3. 完成上述在线与跨环境证据后，再进入阶段四的反馈—遗憾闭环实验。

六、关键指标速览

指标	数值
训练数据	13,348 条转移 · 5,930 episodes · 30 任务
观察反事实	3,600 对有效 · 3,050 对有信息（84.72%）
多种子训练	5 个种子 · 验证集选 3 成员集成
阶段二测试	状态 F1 98.69% · 任务 F1 98.90% · 风险 F1 94.39%
风险校准	ECE 0.0266 → 0.0104
阶段三排序	Pairwise 97.73% · NDCG@2 0.9916 · 集成遗憾 0.0511
多步窗口	H=1 1,943 · H=2 619 · H=3 329
AndroidWorld	API 33 冒烟通过 · 18 个 UI 元素
证据复核	500/500 evidence_verified

七、证据与交付物

- 代码仓库：github.com/yilaxin/agent-world-model（分支 codex/phase2-world-model，草稿 PR #1）；
- 公开看板：<https://yilaxin.github.io/agent-world-model/>（GitHub Pages，与私有 Sites 看板内容一致）；
- 运行证据：data/reports/ 下 phase2_* 训练/评估 JSON、androidworld_preflight_latest.json、androidworld_smoke_latest.json 及截图；
- 报告文件：AndroidWorld真实迁移冒烟验收汇报_2026-08-11.pdf、阶段二阶段三最终进度与遗留问题报告_2026-08-10.pdf；
- GPU 服务器：/root/autodl-tmp/agent_world_model_phase23_latest（权重、日志与结果）。