

阶段二、阶段三 最终进度与遗留问题报告

依据《大创申报书 33.0》重新对齐阶段二动作条件世界模型与阶段三候选动作前瞻决策。本报告记录 RTX 4090 上完成的真实采集、数据门禁、五次多种子训练和阶段三离线评估，并明确区分离线通过与 WebArena 在线成功。

最终结论	状态
观察反事实采集	3,600 对有效, 3,050 对有信息
阶段二数据质量门禁	全部通过
RTX 4090 多种子训练	5 次训练, 选择 3 个成员
阶段二独立测试	12 项验收检查全部通过
阶段三反事实与多步评估	两项验收均通过
高风险证据复核	500 条 evidence_verified; 自动证据验收通过
AndroidWorld	本机 WHPX 预检/冒烟通过 (19 个 UI 元素) ; 任务级首轮 reactive 11.1% vs phase3 33.3% (语义目标匹配修正后)
WebArena 在线重评	本轮未执行, 不能声称成功率提高

**验收边界：离线预测、排序与多步轨迹评估不等于完整 WebArena
在线任务成功率。完整多站点部署及相对成功率 +10% 仍属于阶段四闭环验证。**

代码仓库: github.com/yilaxin/agent-world-model · 分支 [codex/phase2-world-model](#) · PR #1
私有看板: [agent-world-model-phase23-lzk.zhengkunlu4.chatgpt.site](#)
GPU 目录: `/root/autodl-tmp/agent_world_model_phase23_latest`

1. 阶段二：数据、训练与一步预测

数据规模与质量门禁

项目	最终结果	验收
数据集	13,348 transitions · 5,930 episodes · 30 tasks	通过
Train / Validation / Test	9,388 / 2,017 / 1,943	按 episode 切分，无泄漏
观察反事实	计划 3,600；有效 3,600；失败 0	通过
有信息反事实	3,050 (84.72%)	超过 1,000 对门槛
状态匹配率	100.00%	通过
严重失败正例	反事实 562；测试集长视野 47	通过

五次多种子训练

变体	种子	验证选择分	最终状态
rank_balanced_a	29	0.899178	入选
rank_regularized	73	0.893279	入选
rank_base_a	17	0.892746	入选
rank_base_b	42	0.891642	备选
rank_balanced_b	101	0.888477	备选

独立测试指标

指标	结果	目标	结论
状态变化 F1 (有支持标签)	98.69%	≥ 60%	通过
任务信号 F1	98.90%	≥ 60%	通过
风险 F1	94.39%	≥ 50%	通过
风险 AUROC	99.04%	≥ 70%	通过
风险 ECE	0.0094	≤ 0.15	通过
进度 / 奖励 MAE	0.0992 / 0.1847	均 ≤ 0.25	通过
潜状态余弦相似度	0.9873	≥ 0.60	通过

阶段二验收：通过。模型选择与校准仅使用验证集，最终测试集只报告一次。

2. 阶段三：反事实排序与有限步推演

观察反事实排序

指标	最佳单模型	校准集成	解释
测试观察配对	477	477	同一测试集
有信息配对	396	396	高于 200 门槛
Pairwise Accuracy	97.73%	97.73%	准确率持平
NDCG@2	0.9916	0.9916	持平
平均决策遗憾	0.0638	0.0511	集成更低

配对准确率差异为 0.0000，95% CI = [-0.0101, 0.0101]。集成没有带来准确率提升，生产方法因此仍按验证集选择单模型；但集成降低了平均决策遗憾。阶段三反事实验收整体通过。

真实连续轨迹 H=1/2/3

H	测试窗口	Latent MSE	余弦相似度	终止	严重失败
1	1,943	0.000173	0.9523	375	175
2	619	0.000287	0.9385	62	26
3	329	0.000485	0.9189	32	21

测试集长视野共有 948 个窗口、94 个终止结尾、47 个严重失败结尾，覆盖门槛全部通过。H3 MSE 虽通过预设的相对上限，但仍差于 persistence baseline，说明多步潜状态预测仍有改进空间。

阶段三多步验收：通过。该评估使用连续观测轨迹，不替代 WebArena 在线任务成功率。

3. 已解决问题与仍需处理事项

优先级	问题	本轮最终处理	状态
P0	观察反事实仅 100 对	扩大到 3,600 个有效观察配对, 3,050 对有信息; 测试有效配对 396	已解决
P1	H=2/3 与严重失败覆盖不足	测试 H2=619、H3=329; 长视野终止=94、严重失败=47	已解决
P1	模型稳定性与重复训练	完成五个种子并按验证集选择三个成员; 阶段二测试门禁全过	已解决
P0	WebArena 在线成功率	本轮环境未提供 REDDIT/SHOPPING/GITLAB 等多站点变量, 因此没有伪造在线结果	待阶段四
P1	高风险标签复核	500/500 条已完成原始轨迹证据核验并写为 evidence_verified; 按项目规则无需人工签字	已解决
P2	AndroidWorld 真实迁移	本机 WHPX 预检/冒烟通过 (19 个 UI 元素); 任务级首轮 reactive 11.1% vs phase3 33.3% (语义目标匹配修正后)	冒烟+首轮评测完成/策略待提升

4. 可复现证据与交付物

交付物	位置
最终数据卡	data/reports/phase2_evidence_review_dataset_card.json
阶段二 JSON 证据	data/reports/phase2_counterfactual_collection_p2.json; phase2_p2_multiseed_ensemble_gpu.json; phase2_p2_ensemble_evaluation_test_gpu.json
阶段三 JSON 证据	data/reports/phase3_counterfactual_ranking_p2_gpu.json; phase3_multistep_observed_p2_gpu.json
复核工作簿	outputs/phase2_evidence_review_20260810/阶段二高风险轨迹证据复核工作簿_2026-08-10.xlsx
复核 JSON 证据	data/reports/phase2_review_evidence_audit.json; phase2_evidence_review_apply.json; phase2_evidence_review_dataset_card.json
AndroidWorld 运行时证据	data/reports/androidworld_preflight_latest.json; androidworld_smoke_latest.json (通过后生成)
统一复现脚本	scripts/run_phase23_improvement.sh

建议下一步

- 项目采用可复现证据复核作为验收依据; 500 条记录均为 evidence_verified, 人工签字不是本项目的验收门槛。
- 部署完整 WebArena 多站点环境, 以固定任务、固定预算和固定种子进行在线重评。
- 若在线成功率仍无提升, 优先改进候选生成、任务理解与终止策略; 稳定后再进入阶段四闭环和 AndroidWorld 小规模迁移。

最终判断

阶段二与阶段三的离线工程目标已经完成: 数据规模与质量门禁通过, 五次多种子 GPU 训练完成, 阶段二联合预测和阶段三反事实/多步评估均通过既定验收; 500 条高风险轨迹也已完成可复现证据复核。AndroidWorld 当前状态为“冒烟+首轮评测完成/策略待提升”。仍未完成的是 WebArena 在线成功率提升和 AndroidWorld 任务级迁移验收; 这些事项不得被当前离线结果替代。