

阶段二、阶段三 进度与遗留问题报告

依据《大创申报书 33.0》重新对齐：阶段二完成动作条件一步世界模型和状态、进度、风险、终止预测；阶段三完成候选动作生成、1 至 3 步推演、综合评分、结构一致性与有限步重排序。

当前结论	状态
阶段二、阶段三代码原型	已完成并增强
本地自动化测试	58 项通过
历史 RTX 4090 多种子训练	5 次训练，选 3 个模型集成
本轮 P0/P1 增强后的 GPU 重跑	脚本已就绪，待远程终端启动
真实 WebArena 成功率	旧实测 0/5，不能宣称已提高

验收口径：代码存在不等于指标达标；模拟或离线排序不等于真实在线成功率；目标值不写成完成值。WebArena 完整多站点和相对成功率 +10% 属于后续闭环验证，不作为阶段二、三当前已完成结论。

代码仓库：<https://github.com/yilaxin/agent-world-model>
进度看板：<https://agent-world-model-phase23-lzk.zhengkunlu4.chatgpt.site>
Git 提交：742658d · 分支：codex/phase2-world-model · PR #1

1. 与申报书的逐项对齐

阶段	申报书要求	本轮实现	验收状态
阶段二	数据集采集	分组切分、反事实配对、真实多步窗口、人工复核队列与质量门禁	代码完成；扩充采集待 GPU/环境运行
阶段二	LLM 语义世界模型	保留语义状态编码接口；候选适配器支持规则、LLM/VLM 同预算比较	接口完成；具体供应商凭证未绑定
阶段二	可训练一步世界模型	多任务预测头加入 Pairwise RankNet，支持多种子训练、校准和非负集成权重	历史 GPU 训练已验证；增强版待重跑
阶段二	状态、进度、风险、终止预测	状态变化、进度、奖励、成功、停滞、偏离、严重失败和终止联合预测	完成
阶段三	候选动作生成	AXTree 安全候选、目标论坛语义动作、动作合法性校验	完成
阶段三	世界模型推演	1 至 3 步有限推演和真实连续轨迹 $H=1/2/3$ 漂移评测	完成；H3 和严重失败覆盖不足
阶段三	综合评分与结构一致性	短期/长期收益、风险、不确定性、任务元素结构分数联合排序	完成
阶段三	有限步重排序	置信度自适应 $H=1..3$ ，保留重新观察和安全回退	完成

2. 本轮完成的关键改进

- 反事实 P0：按同一初始状态绑定事实动作与受控候选；训练新增成对排序损失；评测只统计真实有差异的配对，给出 bootstrap 区间、遗憾和非劣门禁。
- 数据质量 P1：导出 300 条优先人工复核队列，只有 review_status=approved 且填写 reviewer 的记录才能回写；保留来源和复核元数据。
- 多步 P1：构建不跨 episode、不越过终止状态的连续 $H=1/2/3$ 窗口；新增终止、严重失败覆盖门禁和 H3/H1 漂移门禁。
- WebArena：修复 Reddit 目标论坛定位策略，增加搜索框填充、回车和精确搜索结果点击；步数预算由 6 提高到 12；新增真实同重置反事实任务配置。
- AndroidWorld：预检覆盖 ADB、模拟器、API 33、端口 8554、Python 包、gRPC、Docker/KVM，并提供迁移运行手册。
- 统一运行：scripts/run_phase23_improvement.sh 串联采集、数据门禁、5 次多种子训练、3 模型集成、反事实评测和真实多步评测。

3. 已有真实结果与解释边界

以下数字来自已存在的 RTX 4090 或真实日志结果，不代表本轮增强版已经重跑。

阶段二历史多种子 GPU 结果

指标	结果	说明
训练次数 / 集成规模	5 / 3	5 个种子和配置中选择 3 个成员
测试状态变化 F1	0.9888 ± 0.0011	5 次训练均值与标准差
测试任务信号 F1	0.9795 ± 0.0047	invalid_action、terminal
测试风险 F1	0.8977 ± 0.0181	success、stalled、goal deviation、severe failure
测试风险 AUROC	0.9931 ± 0.0009	存在类别不平衡，需结合 ECE/Brier
校准后风险 ECE	0.0091	集成校准后优于校准前 0.0249
测试进度 MAE	0.0658 ± 0.0048	越低越好

阶段三历史 GPU 决策结果

指标	结果	解释
评测样本	515	离线保留集，不是在线成功率
安全记录动作 Recall@K	1.000	候选集合覆盖记录中的安全动作
有限步合规率	1.000	所有决策均使用 H=1..3
解释完整率	1.000	每次决策给出依据和回退信息
风险动作分流率	0.6655	阶段三对记录风险动作的分流比例
平均决策延迟	20.59 ms	离线 GPU 评测
真实 WebArena	0/5	Reddit 子集旧实测；动作执行率 1.0，但未成功

本地真实连续轨迹漂移评测

H	窗口数	Latent MSE	余弦相似度	终止样本	严重失败
1	231	0.000244	0.9324	34	0
2	124	0.000350	0.9068	11	0
3	59	0.000460	0.8890	5	0

结论：H2 数量和 H3/H1 漂移有界通过；H3 数量、长程终止样本和严重失败样本未达到门禁，且模型 MSE 未优于 persistence baseline，不能标记阶段三多步实证验收通过。

4. 图片中六类问题的处理状态

优先级	问题	本轮处理	剩余工作
P0	WebArena 成功率 0%	修复目标论坛语义导航；步数 6→12；新增受控真实反事实配置	需在线重跑固定任务；完整多站点和相对 +10% 放在阶段四
P0	反事实仅 100 对	三策略采集、Pairwise RankNet、非负集成、bootstrap/非劣门禁；目标 3600 MiniWoB + 15 WebArena 对	需在服务器实际采集和重训；旧 100 对结论仍不变
P1	启发式标签为主	导出 300 条人工复核队列，其中 WebArena 34、终止 166、严重失败 65	当前 300 条均 pending，需要人工检查证据后批准
P1	H2/3 累积偏差	真实连续轨迹评测和 H2/H3/终止/严重失败门禁；增加多步、终止失败采集配置	当前 H3=59、长程严重失败=0，需补采后重训
P2	AndroidWorld 仅适配	完成官方环境预检与迁移手册	本机缺 ADB、模拟器、API33 和运行包；服务器还需确认 KVM
外部	GitHub / Sites	GitHub 已推送；Sites 第 1 版已生产部署并保持仅所有者访问	已解决

5. GPU 多轮训练执行与验收

服务器目录：/root/autodl-tmp/agent_world_model_phase2

在已经连接的 VS Code 远程终端中执行：

命令
git pull --ff-only origin codex/phase2-world-model bash scripts/run_phase23_improvement.sh

- 先采集多步、终止失败和反事实数据，再执行数据质量门禁。门禁失败时停止，防止在不足数据上继续给出乐观结果。
- 通过门禁后执行 5 次多种子训练，按验证集选择 3 个模型，并在独立测试集报告一次最终结果。
- 验收重点：有效反事实配对数、单模型对比的非劣/提升、 $H3 \geq 100$ 、长程终止 ≥ 25 、长程严重失败 ≥ 10 ，以及真实 WebArena SR。
- 当前 Codex 进程无法复用 VS Code 已建立的口令型 SSH 会话，因此没有伪造“本轮训练已启动/完成”的状态。

6. 交付清单与下一步

交付物	位置 / 用途
统一 GPU 流水线	scripts/run_phase23_improvement.sh
反事实 P0 手册	COUNTERFACTUAL_P0_RUNBOOK.md
人工复核工具	scripts/export_human_review_queue.py / apply_human_review_labels.py
多步真实轨迹评测	scripts/evaluate_phase3_multistep.py
AndroidWorld 手册	ANDROIDWORLD_MIGRATION_RUNBOOK.md
本地审计报告	data/reports/phase2_human_review_queue.json / phase3_multistep_observed_cpu_latest.json
在线进度看板	agent-world-model-phase23-lzk.zhengkunlu4.chatgpt.site
GitHub	yilaxin/agent-world-model, 分支 codex/phase2-world-model, PR #1

建议顺序

- 1. 在已连接 GPU 终端运行统一脚本，并保留 data/reports/phase23_improvement_gpu.log。
- 2. 完成 300 条人工复核队列中的高风险与 WebArena 项，再回写训练集。
- 3. 对增强版模型执行固定种子 WebArena 重跑；若仍为 0%，先修代理策略，不用继续堆训练轮数。
- 4. WebArena 稳定后再进入阶段四反馈遗憾闭环，并最后做 AndroidWorld 小规模迁移。

最终判断

阶段二、阶段三的工程链路已补齐到可复现、可审计和可继续训练的状态；历史 GPU 模型和离线阶段三决策具备较好指标。但反事实规模、H3/严重失败覆盖和真实 WebArena 成功率仍未通过严格验收，必须以新一轮服务器结果更新结论。